

CLASSIFICATION DE SOUS-TYPES TUMORAUX PAR MARCHES ALÉATOIRES SPATIALES SUR WSI

MEKKAOUI MOHAMED
FRANZ DERVIS



SUPERVISORS :

PR. NICOLE VINCENT, PR. NICOLAS LOMÉNIE, PR. CAMILLE KURTZ

UNIVERSITÉ PARIS CITÉ M2 VMI

Plan

01	Problématique	●
02	Présentation des données	●
03	Présentation de la solution	●
04	Métriques d'évaluation et résultats	●
05	Conclusion & perspectives	●

01

CHAPITRE

Problématique



Problématique

WSI

Une lame entière (WSI) atteint plusieurs milliards de pixels (jusqu'à $\sim 100\,000 \times 100\,000$) — découpée en patchs de 224 px.

But du projet : **classer le sous-type histologique de chaque patch.**



Un patch isolé est ambigu

À l'échelle d'un seul patch, des sous-types partagent des **patterns visuels très proches** — même un pathologiste s'appuie sur les structures voisines pour trancher.

LÉPIDIQUE

croissance le long des alvéoles



ACINAIRE

structures glandulaires similaires



Notre approche : le contexte spatial

On construit une **séquence de patches voisins** (chemin dans la lame) passée à un **transformer**, qui met les patches en relation pour capturer la structure locale.



Transformer

02

CHAPITRE


Présentation des données



Les 14 classes

6
WSI

Chaque séquence (path) reçoit l'une des 14 étiquettes : contexte tissulaire, tumeur, sous-types architecturaux d'adénocarcinome, stroma et nécrose.




Classes tumorales retenues Contexte tissulaire Tumeur Stroma Nécrose

Présentation des données

7
CLASSES

6
WSI



Correction du grossissement

Un modèle de fondation ne produit de bons embeddings que si les patches lui sont présentés à **l'échelle de son entraînement** . Le grossissement est en fait une **résolution** (µm/pixel).

PROBLÈME Encodeurs (UNI, H-optimus) entraînés en 20× · nos lames scannées en 40× → patches 2× trop zoomés → embeddings hors-distribution.




$448 \text{ px} \times 0,25 \text{ µm/px} = 112 \text{ µm}$

~438 k → ~107 k

patches (~4× moins, cohérent 40× → 20×)

Des embeddings bien séparés

Projection **t-SNE** des embeddings **H-optimus** : des classes nettement séparées.



■ Nécrose

Regroupée à droite, distincte des sous-types tumoraux.

■ Solide

Plusieurs amas cohérents, bien isolés des autres classes.

■ Lépidique

Cluster compact au centre-haut, peu de chevauchement.

À RETENIR

Frontières nettes entre classes = la correction 40× → 20× a restauré la qualité des embeddings.

03

CHAPITRE

Présentation de la solution

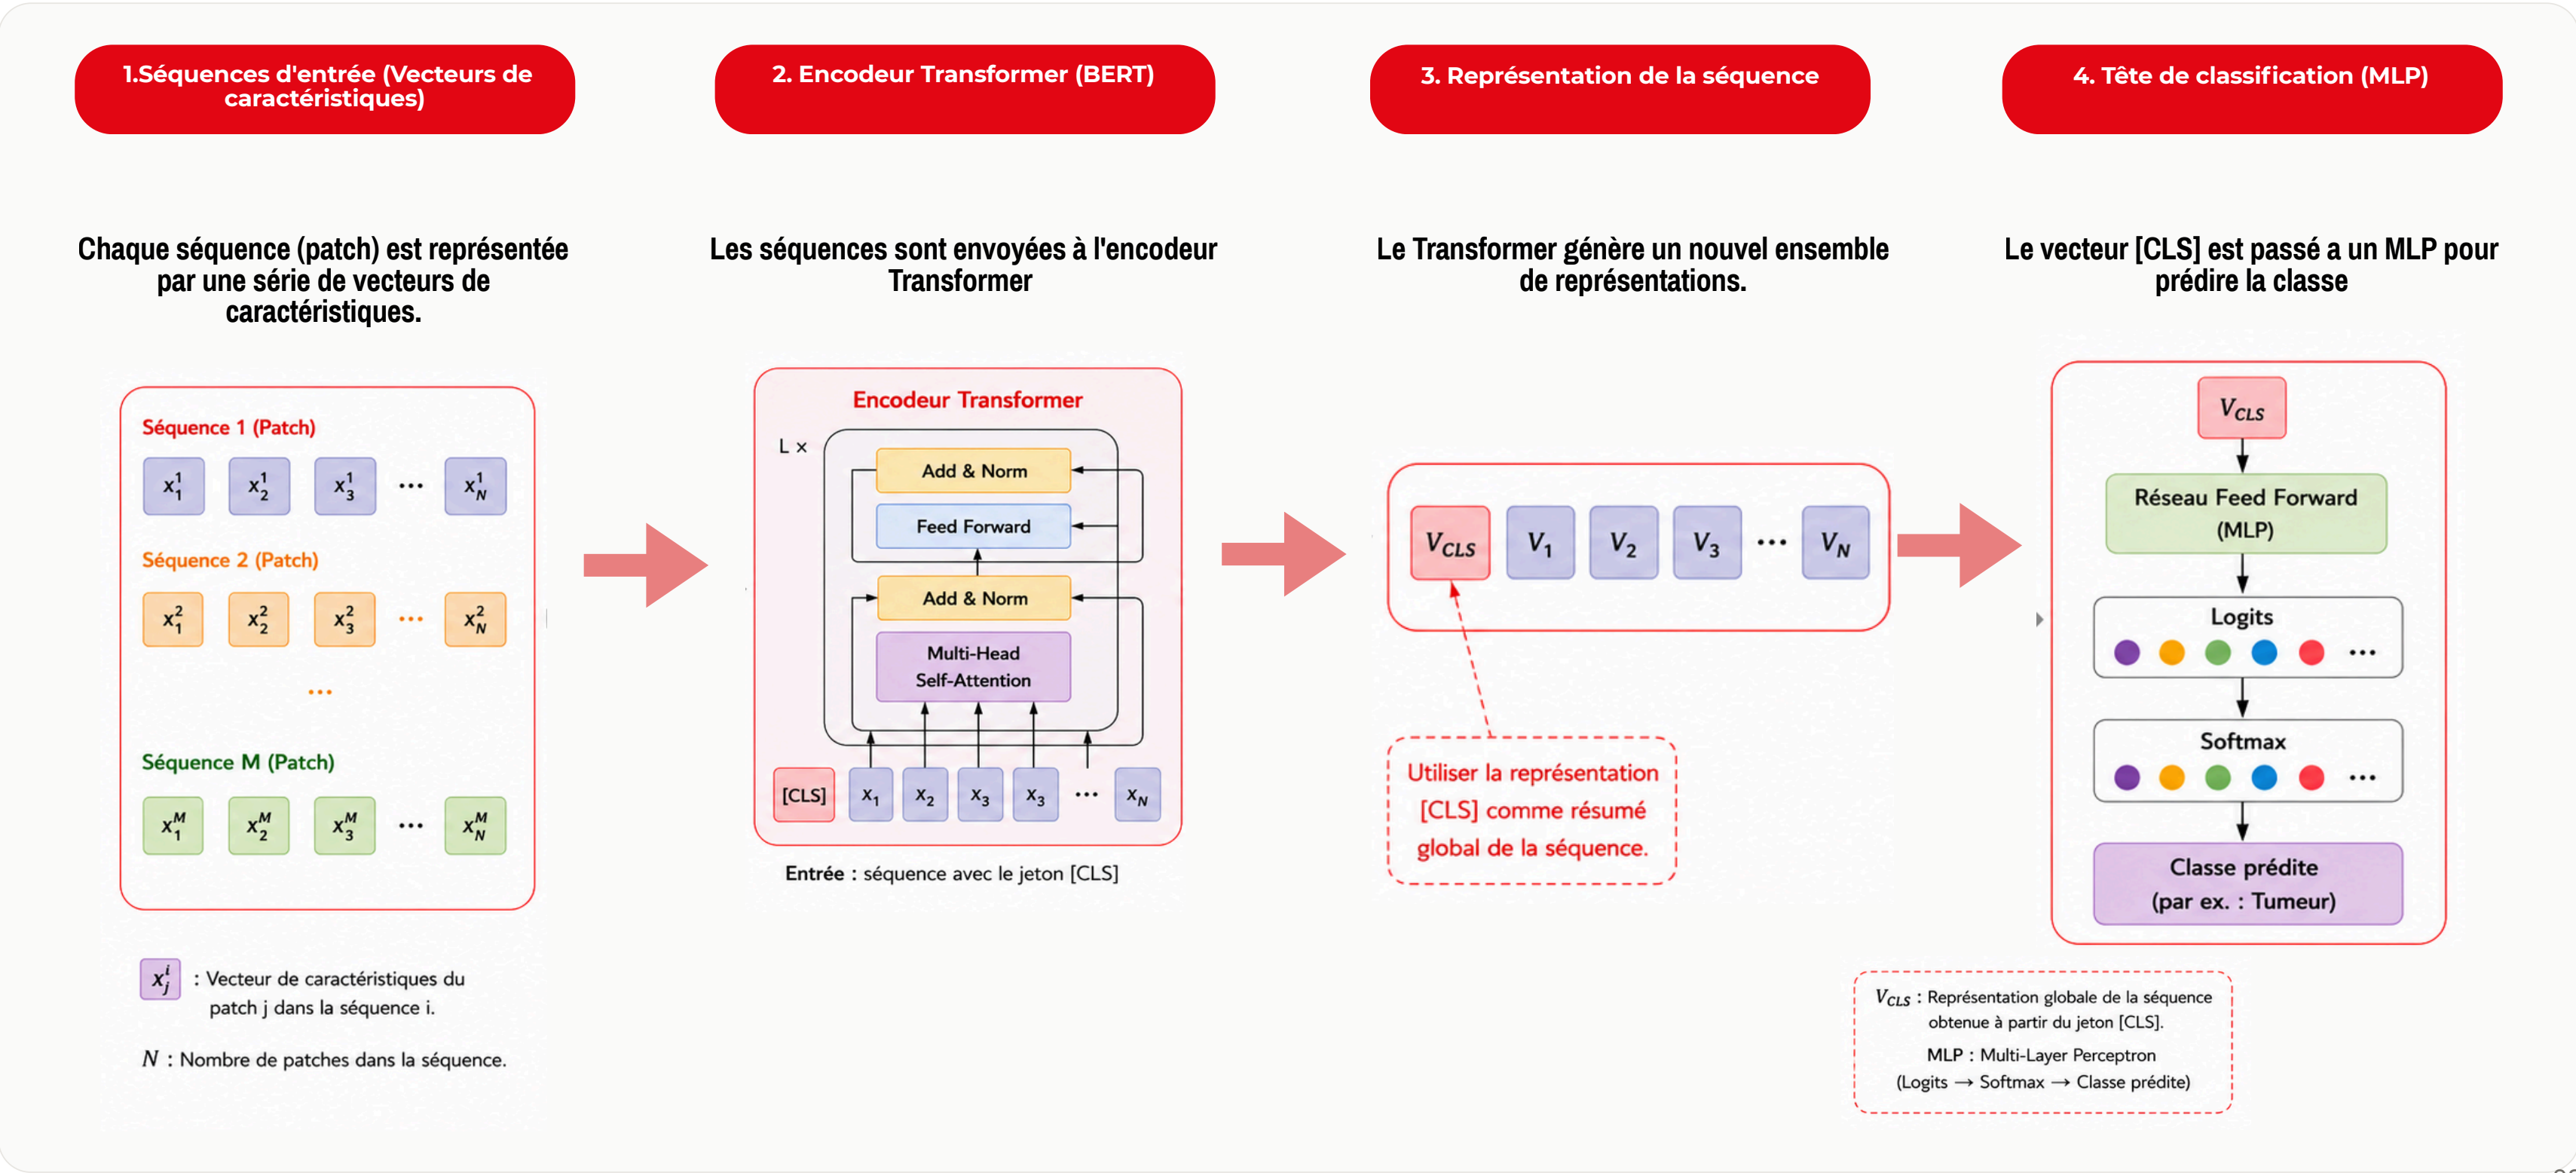


Six encodeurs visuels

Patches bruts extraits via **OpenSlide**, puis passés dans un encodeur **pré-entraîné** chargé via **timm**

DINOv2 vit_base_patch14_dinov2.lvd142m GENERIC VISION 768	ViT vit_base_patch16_224 BASELINE 768	UNI hf-hub:MahmoodLab/uni HISTOLOGY 1024 PATHOLOGY
UNI 2-h hf-hub:MahmoodLab/UNI2-h HISTOLOGY 1536 PATHOLOGY	H-Optimus hf-hub:bioptimus/H-optimus-1 HISTOLOGY 1536 PATHOLOGY	H-Optimus-0 hf-hub:bioptimus/H-optimus-0 HISTOLOGY 1536 PATHOLOGY

Architecture du modèle




Éviter la fuite de données

Des chemins issus d'une même région partagent des patches. Un découpage classique laisse ces patches fuir entre **entraînement**, **validation** et **test**.

PROBLÈME

Découpage par chemins (80 / 10 / 10)

Des patches **communs** se retrouvent dans les trois ensembles.



Patches déjà vus → le modèle mémorise, il ne généralise pas.

SOLUTION

Découpage par régions entières

Chaque ensemble reçoit des **régions distinctes**.



Zéro patch commun → vraie généralisation à du tissu inédit.

Augmentation & équilibrage

Dataset limité (6 lames, 7 classes). Trois stratégies combinées pour exploiter au mieux le tissu annoté.

01


Génération maximale par région

Autant de chemins **uniques** que le tissu le permet.
Doublons et chemins miroirs rejetés à la génération.

+ de données**02**

Inversion des chemins

Chaque chemin d'entraînement est présenté dans les **deux sens**. Validation et test intacts.

**×2 entraînement****03**

Pondération de la perte

CrossEntropy pondérée par l'inverse de la fréquence de chaque classe — atténuée en racine carrée.

```
poids = √( total ÷ (nclasses × chemins  
classe) )
```

classes rares compensées

PAS DE ROTATIONS L'encodeur gelé est déjà entraîné avec rotations et flips : un patch tourné donne un **embedding quasi identique** — aucune information nouvelle.

Paramètres d'entraînement

Modèle d'embedding	UNI — 1024d poids gelés	Encodeur	BERT from scratch, sans pré-entraînement NLP
Blocs Transformer	2 couches NUM_LAYERS = 2	Têtes d'attention	16 NHEAD = 16 · 64d / tête
Dimension cachée	1024d FFN interne : 4096d	Dropout	0.1
Learning rate	2×10^{-4}	Gradient clipping	1.0 norme L2 max
Fonction de perte	CrossEntropy pondérée par classe	Tête de classification	Linear(1024 → 7)

CONFIG FINALE **C'est avec cette configuration que les tests finaux ont été réalisés.**

04

CHAPITRE

Métriques d'évaluation et résultats

Métriques d'évaluation



01 Précision

Parmi les séquences prédites dans une classe, proportion réellement correctes. Calculée par classe.

02 Rappel

Parmi les séquences d'une classe, proportion correctement retrouvées par le modèle.

03 F1-score (macro)

Moyenne harmonique précision / rappel, moyennée sans pondération — même poids aux classes rares.

04 Matrice de confusion

Répartition des erreurs entre classes — révèle les confusions de sous-types (ex. Solide / Papillaire).

Résultats

0.77

PRÉCISION
MACRO


0.82

RAPPEL
MACRO


0.68

F1-SCORE
MACRO

Matrice de confusion




Métriques par classe




Une limite : Solide vs Papillaire

uni2-h — projection t-SNE



uni — projection t-SNE



CONSTAT Nécrose reste bien isolée, mais Solide et Papillaire se chevauchent : difficiles à séparer pour le modèle.

05

CHAPITRE

Conclusion et perspectives



Conclusion & perspectives

■ Conclusion

Classer les patches **avec leur voisinage** (contexte spatial) plutôt qu'isolément.

Sur nos données, cette approche donne de **meilleurs résultats** que la classification directe des patches.

■ Perspectives

Aller plus loin sur la **data augmentation** pour diversifier les données.

Selon **Tellez et al. (2019)**, en pathologie la **stain augmentation** (variation de coloration) est la plus efficace.